

상권 신호등 — 프로젝트 설명

목적과 방향성 · 기술 선택과 이유 · 기술 간 연결(조인트)

1. 프로젝트 목적과 방향성

문제

소상공인은 폐업 직전까지 본인이 위험하다는 사실을 모르는 경우가 많음. 알더라도 어떤 지원제도를 신청해야 하는지 모름. 기존 서비스는 "매출이 얼마", "신용점수가 몇 점" 같은 숫자만 제공함.

목적 — 진단을 행동으로 연결

- 얼마나 위험한가: GREEN / YELLOW / RED 신호등
- 왜 위험한가: 6개 **risk_type** (매출 폭락, 원가 상승, 고금리 과다채무 등)
- 그래서 무엇을 하면 되는가: 원인에 맞는 2026년 정부 지원제도

방향성

공개 데이터만으로 구축함. 개별 점포 매출처럼 공개되지 않은 데이터는 시뮬레이션하되, 시뮬레이션의 시작점과 끝점을 실제 통계로 고정함. 시작점은 서울시 폐업률, 끝점은 신용보증기금 부실사유 분포임. 향후 카드사 실매출 데이터 확보 시 합성 데이터를 실측으로 교체하는 구조임.

2. 어떤 기술을 왜 쓰는가

핵심 원칙: 판단은 ML, 근거는 RAG, 설명은 LLM이 담당함.

역할	기술	선택 이유
원천 데이터 가공	pandas + parquet	42만 행 패널이라 CSV보다 parquet가 빠르고 컬럼 타입이 유지됨. cp949 인코딩과 병합셀 처리도 코드로 통제할 필요가 있었음.
정형 데이터 저장	SQLite (shinhan_warehouse.db)	행정동×업종×분기는 스키마가 고정되어 있고, 업종 내 percentile·다음 분기 shift 같은 윈도우 연산이 핵심임. 따라서 관계형이 적합함.
비정형 데이터 저장	MongoDB	지원제도 원문은 길이가 제각각이고 태그 개수도 가변임. 신호 JSON은 중첩 구조임. 관계형에 넣으면 테이블 3개로 분할해야 함.
위험 예측	LSTM(16) + Dense (Keras)	매출은 순서가 있는 시계열이라 LSTM, 지역·업종 같은 정적 정보는 Dense 브랜치로 분리 입력함. 입력이 3개월로 짧고 데이터도 작아 Transformer는 과함. CPU로 학습 가능한 규모임.
불균형 처리	class_weight="balanced"	가장 비용이 큰 오류는 RED를 GREEN으로 놓치는 것이므로 RED 재현율을 우선함.
제도 검색	RAG (현재 TF-IDF)	문서가 8건이고 "채무조정", "이차보전"처럼 키워드 중심이라 어휘 기반 검색으로 충분함. retrieve() 인터페이스를 고정해 두어 ko-sbert로 교체해도 호출부 수정이 불필요함.
최종 응답	LLM (미구현)	아래 설명 참고.
대시보드	Tableau	지자체·보증재단 등 B2G 고객용. 넓은 단일 테이블로 비정규화하여 내보냄.

"LLM이 전부 하면 되지 않나?"에 대한 답

- **ML로 예측하는 이유:** LLM은 폐업률 percentile 같은 수치를 일관되게 계산하지 못함. 같은 입력에 같은 답이 나와야 하고, 재현율 등 성능 지표로 검증 가능해야 함.
- **RAG를 쓰는 이유:** LLM은 2026년 지원제도를 모르거나 지어낼 수 있음. 공식 공고 문서를 근거로 붙여야 함.
- **LLM이 필요한 이유:** ML은 risk_type 라벨 하나, RAG는 문서 목록만 제공함. "이 사업자 상황에서 이 제도의 신청 조건을 충족하는지, 무엇부터 해야 하는지"를 사람 말로 엮는 역할은 LLM만 가능함.

3. 기술 간 연결 (조인트)

[RAG 사전 준비 · 오프라인, 미리 1회 수행] ★ 청킹 필요 단계

지원제도 문서 수집(기업마당 API 등) → **청킹**(지원대상 / 지원내용 / 신청방법 단위) → 청크마다 risk_type 태그·원문 제도명 메타데이터 부착 → 벡터화 → 인덱스 저장

※ 현재 8건은 짧아 문서 단위 유지 중. 코퍼스 확장 시 필수. 만들어진 인덱스는 아래 RAG 검색 단계에서 사용됨.

[사용자 입력]

- 정형: 업종명, 행정동, 최근 3개월 매출
- 자연어: "재료값이 너무 올라서 힘들어요..."

↓ 조인트 ① 입력 필터링

업종명 → INDUSTRY_MAP → KOSIS_산업1 (원할 피처이자 KOSIS 조인 키)
 행정동×업종 → SQL 웨어하우스 → 폐업률_업종내_percentile
 매출 3개월 → 1개월차 대비 비율로 정규화 → (1, 3, 1) 텐서

↓

[ML: LSTM + Dense] → risk_type + 클래스별 확률

↓ 조인트 ② risk_type이 RAG의 1차 필터

[RAG 검색 · 요청 시]

1차: risk_type 태그로 후보 청크 축소
 2차: 사용자 자연어(+ risk_type 쿼리 문장)로 유사도 정렬 → top-k 청크
 3차: 같은 제도에서 나온 청크는 묶어서 제도 단위로 반환

↓ 조인트 ③ 프롬프트 조립

[LLM]

입력: 예측 결과 + 근거 피처(percentile, 매출 추세) + 검색 문서 + 사용자 원문
 출력: 신호 JSON (risk_level, visual_theme, solutions[] + 설명문)

↓ 조인트 ④ 프론트 계약

[Web 화면 / MongoDB risk_signals 저장]

조인트별 설명

- ① **KOSIS_산업1**: 서울시 패널과 KOSIS 애로사항 데이터를 잇는 유일한 키이자 모델 피처임. 매핑이 빠지면 NaN이 되어 예측과 원인 확률이 함께 깨짐.
- ② **risk_type**: 시스템의 척추임. 라벨 생성, 모델, RAG 쿼리, 문서 태그 네 곳에 같은 6개 분류가 들어감. 한 곳만 바꾸면 연결이 끊김.
- ③ **자연어의 역할**: RAG 앞단에서 사용됨. 현재는 risk_type별 고정 쿼리 문장만 사용하지만, 사용자 자연어를 섞으면 같은 원가상승형 안에서도 "인건비"인지 "재료비"인지에 따라 다른 제도가 검색됨.
- ④ **신호 JSON**: 백엔드와 프론트엔드 사이의 계약임. build_signal_json이 이미 이 스키마를 생성하고 있음.

청킹이 필요한 곳과 필요 없는 곳

대상	청킹 여부	이유
지원제도 문서 (RAG 코퍼스)	필요 (코퍼스 확장 시)	공고문 1건에 지원대상·지원내용·신청방법·제출서류가 섞여 있음. 통째로 벡터화하면 "신청 조건" 질문에 제출서류 부분까지 섞여 유사도가 흐려짐. 항목 단위로 나눠야 LLM에 필요한 부분만 전달 가능함.
청크 메타데이터	필요	청크로 쪼개도 risk_type 태그와 원래 제도명은 모든 청크에 복사해야 함. 그래야 조인트 ②의 태그 필터와 제도 단위 묶음이 유지됨.
사용자 자연어 입력	불필요	한두 문장이라 청킹 대상이 아님. 대신 LLM으로 핵심 고민("재료비 상승")을 뽑아 검색 쿼리로 재작성하는 단계가 더 유효함.
서울시 패널 / KOSIS / 신보 데이터	불필요	정형 표 데이터라 RAG가 아니라 SQL 조회·ML 피쳐로 사용함.

4. 현재 구현 상태

단계	상태
데이터 파이프라인, SQL/Mongo 저장, LSTM 학습, TF-IDF RAG, Tableau	구현 완료 (src/)
사용자 입력 수신, 입력 필터링(조인트 ①) 실시간 수행	미구현. 배치 스크립트만 존재하며 app/ 폴더는 빈 뼈대 상태임
사용자 자연어 → RAG 쿼리	미구현. 현재 risk_type별 고정 문장만 사용함
LLM 최종 생성 단계	미구현. 코드 주석에 "실제로는 LLM이 쿼리 생성"이라고만 기재됨
청킹	문서 8건이 짧아 문서 단위로 처리함. 기업마다 API로 코퍼스 확장 시 지원대상 / 지원내용 / 신청방법 단위 분할 필요

발표 시 반드시 짚을 점

매출 시계열이 모델이 학습하는 위험 등급에서 생성되므로, 보고되는 정확도는 생성 규칙의 복원력을 의미함. 실세계 예측력이 아님. 이를 먼저 밝히고 "카드사 실매출 결합이 실증 단계"라는 로드맵으로 연결하는 편이 질문 방어에 유리함.