

상권 신호등

서울시 상권분석 패널 387,266행으로 행정동×업종 위험 기준선을 만들고, 가상 소상공인 3,000곳의 매출 시계열을 생성해 6개 위험유형을 분류한 뒤 해당 유형에 맞는 2026년 정책 자금을 검색하는 파이프라인입니다. 인코딩 결함 수정 → class_weight 제거 → 표본 30,000곳으로 보강까지 세 차례 수정을 거쳤습니다. 현재 등급 정확도 83.8%(기준선 65.8% 대비 +18.0%p), RED 재현율 93.3%로 신호등이 3단계로 작동합니다. 다만 YELLOW 재현율 33.9%, 6개 유형 중 3개는 여전히 재현율 0%라는 한계가 남습니다. 아래는 각 수정이 무엇을 바꿨는지와, 발표에서 나올 예상 질문 10개입니다.

서울시 상권분석서비스 2023-2025 · 12분기

KOSIS 사업체운영 애로사항

신용보증기금 채권관리 176

TensorFlow 2.21 · LSTM(16)+Dense

TF-IDF RAG · 문서 8건

원천 데이터

seoul_panel_model_ready.csv

패널 행 수

387,266

행정동 425 × 업종 100 × 11분기

타겟 평균

2.64%

중앙값 0 · 3사분위 0 · 최대 300

RAG 문서

8건

새출발자금 · 희망리턴패키지 등

타겟 평균 2.64%가 뜻하는 것

행정동×업종 한 칸에서 다음 분기에 문을 닫는 점포의 비율입니다. 다만 평균이 대표값이 아닙니다.

연율 환산

10.1%

값이 0인 칸

76.5%

10.1%

분기 2.64%가 4번 반복되면.
약 10년에 한 번 점포 교체 속도

7.0%

4칸 중 3칸은 폐업 0건.
중앙값도 3사분위도 0

0 제외 평균

11.2%

일이 생긴 칸에서는
9곳 중 1곳이 폐업


즉 2.64%는 "모든 상권이 고르게 조금씩 위험하다"가 아니라 "대부분은 아무 일도 없고, 일부 칸에서 몰아서 일어난다"는 이중 구조를 평균 낸 값입니다. 조기경보 관점에서는 이 편이 유리합니다 — 위험이 특정 칸에 집중돼 있다는 뜻이기 때문입니다.

왜 0이 이렇게 많은가	점포 5개 이하 칸	점포 20개 초과 칸
전체에서 차지하는 비중	45.9%	—
타겟이 0인 비율	93.7%	36.0%
타겟 평균	2.49%	2.83%

칸이 작아서입니다 — 점포 수 중앙값이 6개이고 4칸 중 1칸은 3개 이하입니다. 점포가 3개면 폐업률은 0 / 33 / 67%처럼 **띄엄띄엄한 계단값**만 가질 수 있어, 연속적인 비율이 아닙니다. 최대값 300%도 같은 이유입니다 — 점포 1개인 칸에서 분기 중 2곳이 폐업하면 200%가 됩니다(104건, 0.03%). **규모로 가중한 실제 서울 폐업률은 3.01%**(총 폐업 197,827 / 총 점포 6,563,310)로, 단순 평균 2.72%보다 높습니다. 큰 상권일수록 회전이 빠르다는 뜻입니다.

분기별 폐업률과 개업률

서울 전체 평균. 2024년 1분기부터 개업률이 폐업률 아래로 내려간 뒤 회복되지 않습니다.



폐업률 상위 업종

3개년 평균, 관측 200셀 이상 업종만. 단위 %

PC방	5.99
기타오락장	5.51
전자상거래업	5.30
패스트푸드점	5.24
양식음식점	5.16
일식음식점	5.07
치킨전문점	5.04
커피-음료	4.79
분식전문점	4.68
독서실	4.61

하위권은 전문직·의료: 동물병원 0.75 · 세무사사무소 0.75 · 일반의원 0.77 · 회계사사무소 0.83. 최상위와 8배 차이입니다.

KOSIS 산업별 폐업률과 원가상승 비중

서울 패널의 평균 폐업률(%)과, KOSIS 애로사항에서 계산한 원가상승형 배정 확률

산 업 대 분 류	폐 업 률	원 가 상 승 확 률
숙박 및 음식점업	4.42	0.464
예술·스포츠·여가	3.38	0.218
교육 서비스업	3.29	0.010
도매 및 소매업	2.50	0.361
부동산업	2.34	0.085
사업시설관리·임대	2.14	0.195
협회·수리·개인서비스	1.83	0.305
전문과학기술서비스업	1.60	0.422

두 축은 거의 무관합니다. 교육 서비스업은 폐업률이 3번째로 높지만 원가상승 확률은 0.01로 최저 — 폐업 원인이 원가가 아니라 경쟁·임대료 쪽임을 뜻합니다.

GREEN · 정상

19,730 곳

65.8% · 평균 score 1.9

YELLOW · 주의

6,189 곳

20.6% · 평균 score 10.4

RED · 위험

4,081 곳


13.6% · 평균 score 30.6

위험군 34.2%는 의도적 과표집입니다. 서울 실제 위험군 비중은 약 14%지만, 그 비율로는 최소 클래스가 학습 9건까지 줄어 모델이 학습되지 않았습니다(BASE_RISK_RATE 0.12 → 0.30). 서비스 적용 시에는 예측 확률을 실제 사전확률로 보정(prior correction)해 되돌려야 합니다.

등급별 평균 매출 궤적

1개월차를 100으로 둔 지수. 모델은 앞 3개월만 보고, 뒤 3개월은 라벨에만 반영됩니다.

--- GREEN 정상 -.- YELLOW 주의 — RED 위험



3개 등급은 1개월차에 이미 벌어져 있습니다 (100.6 / 96.4 / 88.2). 생성기가 등급을 먼저 정하고 그 등급으로 궤적을 그렸기 때문이며, 이것이 아래 정확도 해석의 핵심 배경입니다.

6개 유형의 분포

표본 보강 후, 최소 클래스인 상권_침체_붕괴형이 11곳 → 367곳으로 늘었습니다.

정상_유지형	19,730
단기_매출_정체형	4,206
고금리_과다채무형	2,112
원가_상승_부담형	1,983
매출_폭락형	1,602
상권_침체_붕괴형	367

막대 색은 등급입니다 — ■ GREEN · ■ YELLOW · ■ RED. 최다/최소 클래스 비율이 234 : 1 → 54 : 1로 완화됐습니다.


수정이 드러난 구조적 문제

TREND_BY_LEVEL

유형별 평균 매출 궤적 — RED 3개가 겹칩니다

생성기는 궤적을 **risk_level**로만 정합니다(TREND_BY_LEVEL). 같은 등급 안의 세부 유형은 같은 분포에서 뽑히므로 매출 곡선이 사실상 동일합니다.

— RED 3유형 (겹침) - - - YELLOW 2유형 (겹침) ... 정상_유지형



RISK_TYPE	1개 월	3개 월	6개 월
고금리_과다채무형	88.39	69.36	48.19
매출_폭락형	88.60	69.72	48.91
상권_침체_붕괴형	88.67	69.60	48.61
단기_매출_정체형	96.55	90.02	80.83
원가_상승_부담형	96.54	89.91	80.81

모델이 보는 3개월 시점에서 RED 3유형은 **69.36 / 69.72 / 69.60**입니다. 게다가 RED의 세부 유형은 업종과 무관하게 신보 분포에서 **무작위로 뽑히므로**, 정적 피쳐(업종·폐업률 순위)에도 구분 신호가 없습니다. 즉 **RED 3유형 분류는 원리적으로 학습 불가능합니다**.

표본을 늘려도 이 문제는 그대로입니다. 상권_침체_붕괴형을 11곳 → 367곳으로 33배 늘렸지만 재현율은 여전히 **0%**입니다. 표본 부족이 아니라 신호 부재가 원인이라는 것을 확인해 주는 결과이며, 등급(RED/YELLOW/GREEN) 판별과 세부 유형 판별은 별개의 문제임을 보여줍니다.

수정한 인코딩 결함

generate_synthetic_timeseries.py · 30행

✓ 수정 완료 · 재 실행 반영됨

신보 캘리브레이션이 작동하기 시작했습니다

기존 sgf176_utf8.csv는 4개 인코딩(utf-8-sig / utf-8 / cp949 / euc-kr) 모두에서 디코딩에 실패해 encoding_errors="replace" 경로로 떨어졌고, 부실사유코드가 전부 깨져 **684건** 중 매핑 성공 **0건** — 전량이 fallback 값 매출_폭락형이 됐습니다. 파일을 교체하자 utf-8-sig로 **1,000행**이 읽히고 부실사유코드 14종이 모두 매핑됩니다.

```
# generate_synthetic_timeseries.py - 30행
- sgf = pd.read_csv("sgf176_utf8.csv", encoding=enc)
+ sgf = pd.read_csv("sgf176_utf8_bom.csv", encoding=enc)
```

남은 정리 하나 — 36행의 fallback이 아직 깨진 파일을 가리킵니다. 지금은 도달하지 않는 죽은 경로지만, 디코딩 실패를 조용히 삼켜 캘리브레이션이 죽어도 파이프라인이 정상 종료되게 만든 원인이므로 raise로 바꾸는 편이 안전합니다.

RED 171곳의 유형 배분

수정 전 · 후 실제 산출값

RISK_TYPE	수정 전	수정 후
고금리_과다채무형	0	94
매출_폭락형	171	66
상권_침체_붕괴형	0	11

RAG 문서 중 **새출발기금·신복위 채무조정·희망리턴패키지**가 이제 검색 대상이 됩니다. 수정 전에는 이 3건이 한 번도 노출되지 않았습니다.

실제 부실사유 분포

sgf176_utf8_bom.csv · 1,000건. 이제 이 분포가 RED 배분에 반영됩니다.

기타	198
원금연체	190
신용관리정보	181
이자연체	163
당좌부도	155
휴·폐업	79
관계회사 부실	10
권리침해	8
회생·파산	8
기타 5종	8

연체·부도 계열(원금연체·이자연체·당좌부도·회생파산 등)이 **51.8%**로 과반입니다. 소상공인 부실의 주 원인이 **매출 급락**보다 **채무 상황**이라는 뜻으로, 정책자금 매칭 방향에 직결됩니다.

모델 성능

테스트 600건 · model_predictions_sample.csv

네 단계 수정의 궤적

①~③은 테스트 600건, ④는 6,000건. 현재 저장된 모델은 ④입니다.

지 표	① 버그 4클래스	② 인코딩 수정 + 가중치	③ 가중치 제거 3,000곳	④ 표본 보강 30,000곳 · 현재
다수클래스 기준선	85.7%	85.7%	85.7%	65.8%
등급 정확도	65.0%	26.2%	89.8%	83.8%
기준선 대비 초과분	-20.7%p	-59.5%p	+4.1%p	+18.0%p
GREEN 재현율	61.3%	16.1%	99.8%	97.4%
YELLOW 재현율	78.8%	86.5%	0.0%	33.9%
RED 재현율	100%	85.3%	76.5%	93.3%
RED 정밀도	65.4%	20.1%	96.3%	98.5%
GREEN 오경보	38.7%	83.9%	0.2%	2.6%

④의 등급 정확도 83.8%는 ③의 89.8%보다 낮지만, 훨씬 좋은 모델입니다. 기준선이 85.7% → 65.8%로 내려갔기 때문입니다 — 위험군을 충분히 넣어 "전부 정상"이라 찍는 전략이 더는 통하지 않게 만든 결과입니다. 기준선 대비 초과분이 +4.1%p → +18.0%p로 네 배 이상 늘었고, RED 재현율 76.5 → 93.3%, YELLOW 0 → 33.9%로 신호등이 비로소 3색으로 작동합니다.

등급 정확도

83.8%

기준선 65.8% 대비 +18.0%p

RED 재현율

93.3%

816건 중 761건 · 정밀도 98.5%

YELLOW 재현율

33.9%

0%에서 살아났으나 여전히 미흡

등급 혼동행렬 — 현재 모델

행 = 실제, 열 = 예측. 파란 테두리가 정답 칸입니다.

	예측 GREEN	예측 YELLOW	예측 RED
실제 GREEN	3,845 97.4%	90 2.3%	11 0.3%
실제 YELLOW	817 66.0%	420 33.9%	1 0.1%
실제 RED	55 6.7%	0 0%	761 93.3%

대각선이 살아났습니다. RED 816곳 중 761곳을 잡고(93.3%), 정상을 RED로 잘못 부른 것은 3,946곳 중 11곳(0.3%) 뿐입니다 — 조기경보로 쓸 만한 수준입니다. 남은 약점을 YELLOW 1,238곳 중 817곳이 GREEN으로 새는 것(66.0%)입니다. YELLOW의 매출 궤적이 GREEN과 겹치는 구간이 있어 흡수되며, 이는 관측 창 확대로 개선할 문제입니다.

유형별 재현율 — 현재 모델

괄호는 테스트셋 건수. 등급은 살아났지만 세부 유형은 3개가 여전히 0%입니다.

정상_유지형 97.4% (3946)

고금리_과다채무형 92.2% (422)

단기_매출_정체형	34.6% (841)
매출_폭락형	1.2% (320)
원가_상승_부담형	0% (397)
상권_침체_붕괴형	0% (74)

표본을 367건까지 늘려도 상권_침체_붕괴형은 여전히 0%입니다. 표본 부족이 아니라 **신호 부재**가 원인임을 확인해 주는 결과입니다 — RED 3유형의 3개월 궤적이 **69.36 / 69.72 / 69.60**으로 사실상 같기 때문입니다. 모델은 RED 안에 서 최빈 유형인 고금리(92.2%)로 몰아서 예측하는 최적 전략을 택했습니다. 이 부분은 유형별 궤적 분리 없이는 풀리지 않습니다.

왜 62.2%에서 21.3%로 떨어졌는가 — 원인 분해

class_weight만 빼고 나머지를 전부 고정해 재학습한 결과로 두 원인의 몫을 갈랐습니다.

TRAIN 클 래 스	건 수	BALANCED 가 중 치
정상_유지형	2,056	0.19
단기_매출_정체형	141	2.84
고금리_과다채무형	75	5.33
원가_상승_부담형	66	6.06
매출_폭락형	53	7.55
상권_침체_붕괴형	9	44.44

가중치 최대/최소 비율이 **228**배입니다. 버그 상태(4클래스)에서는 **31**배였습니다 — 인코딩 수정이 RED 171곳을 94/66/**11**로 쪼개면서 학습 9건짜리 클래스가 생겼고, balanced가 여기에 44배 가중치를 얹었습니다. 손실함수가 9건에 끌려다니면서 모델이 희귀 클래스를 남발하게 되고, 정상 재현율이 무너집니다.

다만 가중치를 끄는 것은 **해결책이 아니었습니다**. 실제로 제거해 재학습한 결과 정확도는 87.8%로 올랐지만 **YELLOW 재현율이 0%**가 됐습니다 — 손실이 다수 클래스에 완전히 지배되면서 모델이 **정상과 고금리 두 라벨만** 사 용하게 된 것입니다. 가중치를 켜면 과잉경보, 끄면 과소경보로 **실패의 방향만 바뀝니다**.

결론 — 클래스 가중치는 원인이 아니라 증상입니다. 진짜 원인은 **생성 단계에서 만들어진 극단적 불균형**입니다. 위험군 비중이 14.3%에 불과하고(BASE_RISK_RATE=0.12), 최소 클래스는 학습 9건입니다. 이 상태에서는 가중치를 어떻게 조정해도 과잉·과소 경보 사이를 오갈 뿐이며, **표본 자체를 늘리는 것만이 해법**입니다. ※ 재학습은 실행마다 흔들립니다(시드 고정에도 학습 비결정성 존재). 가중치 적용 시 21~29%, 제거 시 87~89% 범위이며 방향은 재현됩니다.

실행 경로

각 단계는 앞 단계의 출력 파일을 읽습니다

01
zip 3개 병합
→ seoul_panel_raw.p
arquet

02
패널 전처리 · 업종 매핑
→ seoul_panel_model
_ready.csv

03
KOSIS 애로사항 조인
→ yellow_subtype_pr
ob.csv

04 ✓
가상 시계열 생성
→ synthetic_compani
es.csv

05 ✓
LSTM 학습
→ risk_model.keras

06
RAG 검색 · 신호
JSON
→ solutions[]

✓ 표시된 04·05단계를 세 차례(인코딩 → class_weight → 표본 보강) 재실행했습니다. 01–03단계는 입력이 바뀌지 않아 재실행이 불필요합니다.

다음 수정

권고 · 아직 적용하지 않음

✓ 적용 완료 · ① 표본 보강

불균형을 생성 단계에서 해소했습니다

가중치를 켜고 끄는 것은 과잉경보와 과소경보를 오갈 뿐이라는 것이 두 번의 재학습으로 확인됐고, 근본 원인이 생성 단계의 불균형이라고 판단해 아래를 적용했습니다. 최소 클래스가 학습 9건 → 293건이 되면서 RED 재현율 76.5 → 93.3%, YELLOW 0 → 33.9%로 개선됐습니다.

```
# generate_synthetic_timeseries.py
- N_COMPANIES = 3000
+ N_COMPANIES = 30000
- BASE_RISK_RATE = 0.12
+ BASE_RISK_RATE = 0.30 # 위험군 14.3% → 34.2% (의도적 과표집)

# train_risk_model.py
+ USE_CLASS_WEIGHT = False
```

남은 과제 — YELLOW 재현율 33.9%는 아직 낮습니다. YELLOW 1,238곳 중 817곳이 GREEN으로 새는데, 두 등급의 매출 궤적이 겹치는 구간이 있기 때문입니다. 관측 창을 3개월에서 늘리는 것이 다음 지렛대입니다.

표본 보강의 실제 효과 — 측정했습니다

원본 파이프라인을 건드리지 않고 동일 로직을 재현해, 변경 단계별 효과를 분리 측정한 결과입니다.

지 표	A. 현 재	B. 표 본 보 강	C. + 유 형 별 궤 적
	3,000 / 0.12	30,000 / 0.30	제안값 적용

최소 클래스가 학습 가능

✓

✓✓✓

✓✓✓✓

최소 클래스 익급 간주	9	293	293
다수클래스 기준선	85.7%	65.8%	65.8%
등급 정확도	89.3%	83.2%	79.1%
기준선 대비 초과분	+3.6%p	+17.4%p	+13.3%p
GREEN 재현율	99.8%	96.9%	98.0%
YELLOW 재현율	0.0%	31.6%	18.5%
RED 재현율	67.6%	95.2%	79.5%
매출_폭락형 재현율	0.0%	0.0%	85.6%

B는 명백한 개선입니다. 등급 정확도(89.3 → 83.2%)만 보면 나빠진 듯하지만 기준선이 85.7 → 65.8%로 함께 내려갔기 때문입니다. **기준선 대비 초과분은 +3.6%p → +17.4%p로 다섯 배 가까이 늘었고, 무엇보다 RED 재현율 67.6 → 95.2%, YELLOW 0 → 31.6%로 신호등이 비로소 3단계로 작동하기 시작합니다.**

② 유형 별 계 적 - 제 안 값 은 재 설 계 필 요

C안은 등급 구분을 희생해서 유형 구분을 샀습니다

앞서 제안했던 TREND_BY_TYPE 값을 실제로 적용해 보니 **매출_폭락형이 0 → 85.6%로 살아난 대신, RED 재현율이 95.2 → 79.5%, YELLOW가 31.6 → 18.5%로 떨어졌습니다.** 원인은 제안값의 구간이 등급 경계를 가로질러 겹쳤기 때문입니다 — 고금리(-0.10~-0.05)와 원가상승(-0.05~-0.02)이 맞닿아 RED/YELLOW 경계가 흐려졌습니다.

올바른 설계 원칙은 **등급 밴드는 벌리고, 유형은 밴드 안에서 구분하는 것**입니다. 기울기는 등급을 결정하고, 유형은 **변동성·형태**로 가르는 편이 안전합니다.

```
# 등급 밴드를 유지하면서 유형을 가르는 재설계안
TREND_BY_TYPE = {
  # RED 밴드: 전부 가파름(≤ -0.08). 유형은 변동성으로 구분
  "매출_폭락형": (-0.22, -0.16, 0.04), # 최급락 · 안정적
  "고금리_과다채무형": (-0.14, -0.10, 0.10), # 급락 + 큰 진폭
  "상권_침체_붕괴형": (-0.12, -0.08, 0.02), # 급락 + 매우 매끄러움
  # YELLOW 밴드: 완만(-0.06 ~ 0.00)
  "원가_상승_부담형": (-0.06, -0.035, 0.02), # 꾸준한 완만 하락
  "단기_매출_정체형": (-0.03, 0.00, 0.07), # 정체 + 들쭉날쭉
  "정상_유지형": (-0.01, 0.02, 0.04),
}
```

다만 한계가 있습니다 — 관측이 3개월이면 차분이 2개뿐이라 **변동성을 추정할 표본이 부족합니다.** 변동성을 유형 구분자로 쓰려면 관측 창을 **최소 6~12개월**로 늘려야 하며, 이는 7번 질문(왜 3개월인가)과 직결됩니다.

③ 유 의

위험군 비중을 35%로 올리면 사전확률이 실제와 달라집니다

BASE_RISK_RATE=0.30은 학습을 위한 **의도적 과표집**입니다. 서비스에 쓸 때는 예측 확률을 실제 위험군 비중(약 14%)으로 **사전확률 보정**해 되돌려야 하며, 그러지 않으면 모든 사업자의 위험도가 실제보다 과대 추정됩니다.

예상 질문 10

근거 수치와 답변 방향

A 데이터 신뢰성

01

매출 시계열이 전부 가상인데, 이 모델의 성능을 신뢰할 수 있습니까?

근거

3,000곳의 6개월 매출이 모두 **시뮬레이션**입니다. 개별 점포의 월매출은 국세청·카드사만 보유해 공개 데이터가 없습니다.

답변 방향

시뮬레이션의 **양 끝은 실측으로 고정**했습니다 — 출발점(어느 동네·업종에서 시작할지)은 서울시 실제 폐업률 분포로, 도착점(어떤 사유로 부실화되는지)은 신보 실제 부실사유 분포로 잡았습니다. 다만 그 사이의 월별 궤적은 가정(TREND_BY_LEVEL)입니다. 따라서 현재 산출물은 **파이프라인 동작 검증용이지 성능 근거가 아니라고** 먼저 선을 긋고, 실서비스에서는 이 구간을 카드 매출·입출금 데이터로 교체하는 것이 전제라고 답합니다.

02

타겟인 다음분기 폐업률이 중앙값 0, 3사분위도 0입니다. 예측 대상으로 성립합니까?

근거

387,266행 중 평균 **2.64**, 중앙값 **0**, 75% 지점 **0**, 최대 **300**. 즉 **과반이 0인 zero-inflated 분포**이고, 최대값 300%는 점포가 1~2개뿐인 셀에서 나온 값입니다.

답변 방향

그래서 이 값을 회귀 타겟으로 직접 쓰지 않고 폐업률_업종내_percentile, 즉 **같은 분기·같은 업종 안에서의 상대순위**로 변환해 사용합니다. 0이 많아도 순위는 정의되므로 문제를 우회합니다. 다만 300% 같은 이상치를 막으려면 **점포수 하한 필터(예: 5개 이상)**가 추가로 필요하다는 점은 한계로 인정합니다.

업종 100개를 KOSIS 12개로 줄인 매핑의 근거는 무엇입니까?

근거

INDUSTRY_MAP은 수작업 하드코딩입니다. 특히 **보건업**(일반의원·치과의원·한의원·동물병원)은 KOSIS 표에 대응 항목이 없어 '협회 및 단체, 수리 및 기타 개인서비스업'에 임시 배치돼 있습니다.

답변 방향

KOSIS 애로사항 데이터와 조인하기 위한 **근사 매핑**임을 인정합니다. 다행히 의료업은 폐업을 최하위권(동물병원 0.75%, 일반의원 0.77%)이라 위험군 선별에 미치는 영향이 작습니다. 정식 해법은 통계청 표준산업분류(KSIC) 코드 기반 매핑이며, 두 데이터가 모두 KSIC를 갖고 있어 전환 비용은 낮습니다.